

FakeNewsSetGen: a Process to Build Datasets that Support Comparison Among Fake News Detection Methods

Flávio Roberto Matias da Silva
Paulo Márcio Souza Freire
flavio.matias@ime.eb.br
paulomsfreire@ime.eb.br

Marcelo Pereira de Souza
Gustavo de A. B. Plenamente
mpsouza@ime.eb.br
gustavo.plenamente@ime.eb.br

Ronaldo Ribeiro Goldschmidt
ronaldo.rgold@ime.eb.br
Instituto Militar de Engenharia (IME)
Rio de Janeiro, RJ, Brasil

ABSTRACT

Due to easy access and low cost, social media online news consumption has increased significantly for the last decade. Despite their benefits, some social media allow anyone to post news with intense spreading power, which amplifies an old problem: the dissemination of Fake News. In the face of this scenario, several machine learning-based methods to automatically detect Fake News (MLFN) have been proposed. All of them require datasets to train and evaluate their detection models. Although recent MLFN were designed to consider data regarding the news propagation on social media, most of the few available datasets do not contain this kind of data. Hence, comparing the performances amid those recent MLFN and the others is restricted to a very limited number of datasets. Moreover, all existing datasets with propagation data do not contain news in Portuguese, which impairs the evaluation of the MLFN in this language. Thus, this work proposes *FakeNewsSetGen*, a process that builds Fake News datasets that contain news propagation data and support comparison amid the state-of-the-art MLFN. *FakeNewsSetGen*'s software engineering process was guided to include all kind of data required by the existing MLFN. In order to illustrate *FakeNewsSetGen*'s viability and adequacy, a case study was carried out. It encompassed the implementation of a *FakeNewsSetGen* prototype and the application of this prototype to create a dataset called *FakeNewsSet*, with news in Portuguese. Five MLFN with different kind of data requirements (two of them demanding news propagation data) were applied to *FakeNewsSet* and compared, demonstrating the potential use of both the proposed process and the created dataset.

CCS CONCEPTS

• **Security and privacy** → **Social network security and privacy**; *Web application security*; • **Information systems** → *Data mining*; *Web mining*; *Social networks*.

KEYWORDS

Dataset building process, Fake News detection, social media

ACM Reference Format:

Flávio Roberto Matias da Silva, Paulo Márcio Souza Freire, Marcelo Pereira de Souza, Gustavo de A. B. Plenamente, and Ronaldo Ribeiro Goldschmidt. 2020. FakeNewsSetGen: a Process to Build Datasets that Support Comparison Among Fake News Detection Methods. In *Brazilian Symposium on Multimedia and the Web (WebMedia '20)*, November 30-December 4, 2020, São Luís, Brazil. ACM, New York, NY, USA, 8 pages. <https://doi.org/10.1145/3428658.3430965>

1 INTRODUÇÃO

Historicamente, a publicação de notícias se restringia à mídia tradicional, como rádio, TV, revistas e jornais. Todavia, devido ao fácil acesso e baixo custo, as pessoas vêm, a cada dia, aumentando o consumo de notícias on-line [34]. Este consumo é realizado por intermédio dos meios digitais de divulgação de notícias (MDDN), compostos, basicamente, pelas mídias virtuais (e.g.: jornais e revistas on-line) e, em especial, pelas redes sociais virtuais (RSV).

Apesar de seus benefícios, algumas RSV permitem que qualquer pessoa, independentemente de sua credibilidade, divulgue (publique/propague) notícias com intenso poder de espalhamento [29, 35]. Tal permissividade amplificou um problema antigo: a disseminação de notícias falsas [40]. Esse problema pode se tornar ainda mais prejudicial quando essas notícias são divulgadas intencionalmente, pois uma inverdade deliberada tende a ser melhor elaborada e mais eficaz em seu objetivo principal, que é influenciar na mudança de opinião [8]. Esse tipo particular de notícia falsa, cuja divulgação acontece de forma proposital, é denominado de *Fake News* [29].

Abaixo seguem exemplos de casos significativos que ilustram a importância de se combater a disseminação das Fake News:

- Um homem, carregando um rifle AR-15, aterrorizou os frequentadores de uma pizzaria em *Washington*, porque ele havia lido uma notícia falsa on-line, afirmando que o referido estabelecimento usava crianças como escravas sexuais [6];
- Segundo o jornal on-line *G1*, uma dona de casa morreu dois dias após ter sido espancada por dezenas de moradores do município de Guarujá em São Paulo. De acordo com o jornal, ela foi agredida a partir de uma notícia falsa, divulgada por uma rede social, que atribuía à dona de casa o sequestro de crianças para utilizá-las em rituais de magia negra;
- As inúmeras notícias falsas sobre a *COVID-19* têm dificultado de forma significativa o esclarecimento da população brasileira sobre a disseminação da pandemia e a respeito das devidas medidas de enfrentamento da doença [17].

Diante desse cenário, tanto a academia quanto a indústria têm pesquisado como combater *Fake News* disponibilizadas em MDDN [8]. Contudo, esse problema apresenta-se como não trivial, tanto

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

WebMedia '20, November 30-December 4, 2020, São Luís, Brazil

© 2020 Association for Computing Machinery.

ACM ISBN 978-1-4503-8196-3/20/11...\$15.00

<https://doi.org/10.1145/3428658.3430965>

pelo volume de publicações quanto pela velocidade das suas respectivas propagações. Assim, o emprego de abordagens computacionais, devido à sua maior velocidade de atuação, vem se destacando no combate às *Fake News* [27].

Grande parte dos métodos pertencentes a essas abordagens utiliza aprendizado de máquina para a classificação de notícias em *fake* e não *fake* [8]. Esses métodos precisam treinar, validar e testar modelos a partir de *datasets*, compostos de diferentes atributos de diversos tipos, como os relacionados ao conteúdo das notícias e aqueles referentes à propagação dessas notícias. Assim, *datasets* que possuam uma variedade de atributos são importantes para o desenvolvimento, a aplicação e comparação desses métodos.

Embora o estudo de *Fake News* como tópico de pesquisa, especialmente na área de Ciência da Computação, seja relativamente recente, já existe significativa literatura disponível que diz respeito à utilização de *datasets* compostos por notícias no idioma inglês. No entanto, *datasets* cujo conteúdo esteja expresso na língua portuguesa ainda são raros [8, 20]. Além disso, independentemente do idioma, há uma carência de *datasets* com dados referentes à propagação de notícias em MDDN [8]. Ainda mais sensível é o fato de que, até onde foi observado, nenhum dos *datasets* com notícias em português disponibiliza dados de propagação. A ausência desses dados em *datasets*, por sua vez, inviabiliza a aplicação e comparação de uma significativa parcela de métodos de detecção de *Fake News*.

Diante do exposto, o presente trabalho tem como objetivo propor um processo de construção de *datasets* com notícias na língua portuguesa que contenham tanto dados sobre o conteúdo das notícias quanto dados referentes às suas propagações. Desse modo, *datasets* criados a partir do processo proposto viabilizam a aplicação e a comparação de métodos do estado da arte na detecção de *Fake News* em MDDN com diferentes demandas de dados (e.g. conteúdo e/ou propagação). Esse processo foi desenvolvido com base em requisitos que foram levantados a partir da demanda de dados dos métodos de detecção de *Fake News* do estado da arte. Como forma de apresentar a viabilidade e adequação do processo proposto, foi realizado um estudo de caso que envolveu a implementação de um protótipo customizado para utilizar a rede social *Twitter*, bem como as agências de checagem de fatos *Lupa*, *Aos Fatos* e *AFP*. A partir do *dataset* criado nesse estudo de caso, foram aplicados e comparados cinco diferentes métodos de detecção de *Fake News* com diferentes demandas de dados (sendo dois com demanda por dados de propagação), demonstrando o potencial de utilização tanto do processo quanto do *dataset* criado.

Este artigo está organizado em mais quatro seções. A Seção 2 descreve os trabalhos relacionados, por intermédio da proposta e da aplicação de um modelo comparativo. A Seção 3 apresenta o processo de construção de *datasets* proposto. Já o estudo de caso é apresentado na Seção 4, por meio do detalhamento do protótipo, da descrição das peculiaridades do *dataset* gerado e da avaliação da aplicação dos métodos de detecção de *Fake News*. Por fim, a Seção 5 apresenta as considerações finais, destacando as contribuições e os principais resultados obtidos pelo presente trabalho.

2 TRABALHOS RELACIONADOS

Este estudo considera trabalhos que de alguma forma constroem *datasets*, mesmo que essa construção não seja o objetivo principal

de alguns desses trabalhos, já que vários deles destinam-se, principalmente, à criação de métodos de detecção automática de *Fake News*.

A fim de facilitar a análise dos trabalhos relacionados, um modelo comparativo é proposto e aplicado. Para tanto, critérios foram estabelecidos a partir de características comuns entre os *datasets* pertencentes aos trabalhos do estado da arte pesquisados.

2.1 Proposta de Modelo Comparativo

Os seguintes critérios compõem o modelo comparativo proposto:

- **Dados de Publicação (C1)** - Esse primeiro critério indica se o *dataset* apresentado pelo trabalho contém dados referentes ao momento em que a notícia surge no meio digital (i.e. dados de publicação), como título, texto, imagem ou áudio. Esses dados são utilizados por uma considerável parcela de métodos de detecção de *Fake News* que atua, principalmente, na área de análise de texto [8].
- **Dados de Propagação (C2)** - Esse critério revela a utilização de dados obtidos a partir da propagação da notícia em MDDN. Inclusive, esses dados podem ser ainda mais relevantes do que os dados de publicação da notícia [16], pois podem reunir, por exemplo, além de dados adicionais de contribuição à publicação original, características de usuários e dos respectivos perfis. Além disso, por meio desses dados, pode ser gerada a rede de propagação da notícia, definida por meio de grupos de contas de usuários seguidores e seguidos, oferecendo, dessa forma, um vasto campo para análise.
- **Idioma Português (C3)** - Esse critério indica se o *dataset* possui notícias no idioma português. Métodos de detecção de *Fake News*, principalmente os que utilizam abordagens voltadas para análise de texto, em grande parte, são aplicados especificamente a *datasets* com notícias em um único idioma, em decorrência das especificidades de cada língua [4, 8].
- **Modelo de Dados Conceitual (C4)** - Esse critério indica se o trabalho analisado possui uma abstração do *dataset* utilizado. Essa abstração pode ser expressa por meio de uma modelagem conceitual que pode ser usada para representar níveis mais altos de abstração dos dados, em prol da facilitação de um maior entendimento de aspectos essenciais à descrição do problema. Dessa forma, um modelo de dados conceitual facilitaria a compreensão do *dataset* utilizado em cada trabalho.
- **Politémico (C5)** - Esse critério indica se o *dataset* contém notícias sobre mais de um tema. Apesar de o debate midiático a respeito de *Fake News* abordar demasiadamente a área política, essas notícias não se restringem a um único tema. Entretanto, uma parcela dos *datasets* utilizados para detecção de *Fake News* contém apenas notícias monotemáticas [3]. Apesar disso, a pluralidade de temas nos *datasets* é importante para que a aplicação de métodos de detecção de *Fake News* não se restrinja a um tema específico [18].
- **Atualizável (C6)** - Esse critério indica se existe um processo que viabilize a atualização do *dataset* com novas notícias. Com o passar do tempo, *Fake News* vêm sendo elaboradas de forma cada vez mais sofisticada a fim de enganar métodos de detecção [29]. Logo, espera-se que *datasets* possam de alguma forma ser atualizados com notícias recentes para mitigar esse problema.

- **Agência de Checagem de Fatos (C7)** - Esse critério indica se o *dataset* utiliza notícias previamente rotuladas em *fake* ou não por agências especializadas em checagem de fatos. Atualmente, existem 225 dessas agências ativas no mundo, de acordo com o site da Duke Reporters LAB¹. Cada uma dessas agências segue o código de conduta e princípios éticos² da *International Fact-Checking Network* (IFCN), sediada no *Poynter Institute*, nos Estados Unidos. Dessa forma, a utilização de notícias coletadas dessas agências fornece credibilidade ao processo de rotulação do *dataset*.
- **Processo de Construção Definido (C8)** - Esse critério revela se o trabalho definiu e demonstrou o processo utilizado para a construção do *dataset*. O detalhamento das etapas metodológicas de construção podem viabilizar a implementação de diferentes protótipos e, conseqüentemente, a criação de diferentes instâncias de *datasets* compatíveis com diferentes métodos de detecção [30].

2.2 Análise dos Trabalhos Relacionados

Até onde foi possível observar, conforme descrito na Tabela 1, foram identificados trinta e cinco trabalhos relacionados, mas, desse conjunto, apenas sete descrevem o processo de construção do *dataset*. Logo, esses sete são brevemente descritos e seus detalhes podem ser consultados por intermédio das respectivas referências:

- **Bracis2019FakeNews** [22] - Dois *datasets* foram construídos nesse trabalho. O primeiro é baseado em textos de 115 notícias falsas e 12 verdadeiras divulgadas pelo *WhatsApp*, já o outro é composto por 87 identificadores de postagens falsas e por 21 de postagens verdadeiras, coletadas do *Twitter*. O texto das mensagens do *WhatsApp* e as postagens relacionadas aos identificadores do *Twitter* estão no idioma português. Esses *datasets* contêm dados de publicação da notícia, mas não armazenam dados referentes à sua propagação. O acesso a esse trabalho pode ser realizado por meio do repositório *github* do projeto³.
- **Factck.Br Corpus** [20] - Esse *dataset* é composto por textos de 1313 notícias no idioma português que foram verificadas individualmente por agências de checagem de fatos brasileiras. Possui como principal característica o fato de ser atualizável, ou seja, há uma API que possibilita a atualização do *dataset* com novas notícias analisadas por agências de checagem. Esse *dataset* contém dados de publicação da notícia, mas não armazena dados referentes à sua propagação. Todo o projeto pode ser acessado por meio de seu respectivo repositório *github*⁴.
- **FakeBr Corpus** [18] - Esse é um dos primeiros *datasets* disponibilizados para viabilizar a construção de modelos de detecção de *fake news* no idioma português. Possui 7200 notícias, das quais 3600 são consideradas verdadeiras, obtidas em versões digitais de mídias virtuais e as outras 3600, obtidas em sites considerados propagadores de notícias falsas, são rotuladas como 'fake'. Esse *dataset* contém dados de publicação da notícia, mas não armazena dados referentes à sua propagação. O acesso a esse *dataset* pode ser realizado por meio do repositório *github* do projeto⁵.
- **FakeNewsNet1** [29] - Esse *dataset* foi coletado do *Twitter* e contém 211 notícias rotuladas como 'Fake' e outras 211 como 'Real', obtidas a partir das agências de checagem de fatos americanas *BuzzFeed* e *PolitiFact*. Ele contempla tanto dados de publicação quanto dados de propagação de notícias no idioma inglês. Todo esse trabalho pode ser acessado por meio seu respectivo repositório *github*⁶.
- **FakeNewsNet2** [30] - Esse trabalho, além de disponibilizar um *dataset*, propõe um processo de construção de *datasets* multi-dimensionais que viabilize diferentes pesquisas relacionadas à detecção de *Fake News*. O *dataset* disponibilizado é composto por 5.808 notícias rotuladas como 'Fake' e outras 16.987 como 'Real', coletadas a partir das agências de checagem de fatos americanas *GossipCop* e *PolitiFact*. Esse *dataset* contempla tanto dados de publicação quanto dados de propagação de notícias no idioma inglês. Uma implementação do processo e o *dataset* podem ser acessados pelo repositório *github* do projeto⁷.
- **FakeTweet.Br Corpus** [4] - Esse *dataset* foi construído para detecção *Fake News* escritas em língua portuguesa e é composto por 206 notícias falsas e 94 verdadeiras. Apesar dos dados terem sido coletados a partir do *Twitter*, ele só contém o texto de publicação das notícias. O acesso ao *dataset* pode ser realizado através do seu respectivo repositório *github*⁸.
- **LIAR** [36] - Esse *dataset* foi coletado da agência de checagem de fatos *PolitiFact* e, dessa forma, é composto por notícias no idioma inglês. Ele inclui 12.836 notícias rotuladas manualmente como 'Pants-fire', 'False', 'Barely-true', 'Half-true', 'Mostly true' e 'True'. Tanto dados de publicação quanto de propagação de notícias estão presentes no *dataset*, mas cabe salientar que os dados referentes ao usuário se resumem ao nome do autor da postagem. O *dataset* pode ser obtido pelo link da *University of California Santa Barbara (UCSB)*⁹.

No início, as notícias *fake* e não *fake* possuíam formas muito distintas, mas, com o passar do tempo, a variação das características dessas notícias se torna cada vez mais sutil, de forma a dificultar a detecção por meio do próprio conteúdo. Sendo necessário, dessa forma, efetuar a exploração além do conteúdo de notícias [30], como por meio do envolvimento de usuários e dos dados de propagação. No entanto, o presente estudo identificou que poucos trabalhos disponibilizam *datasets* com esses dados, o que restringe consideravelmente a aplicação de métodos de detecção de diferentes abordagens.

Outro importante fato observado refere-se ao idioma. Grande parte dos métodos de detecção de *Fake News* são dependentes de um idioma específico, devido não somente às variações linguísticas da notícia, mas também à grande quantidade de variáveis relacionadas às características dialéticas regionais que complementam a notícia, como, por exemplo, o uso de diferentes gírias e jargões na composição de comentários e *hashtags* [41].

Assim, pesquisas sobre aplicação de métodos específicos para o idioma português são necessárias. Entretanto, até onde foi observado por esta pesquisa, há apenas quatro iniciativas de construção de *datasets* com notícias no idioma português [4, 18, 20, 22]. Além

¹<https://reporterslab.org/fact-checking/>

²<https://www.poynter.org/international-fact-checking-network-fact-checkers-code-principles>

³https://github.com/phfaustini/BRACIS2019_FAKENEWS

⁴<https://github.com/jghm-f/FACTCK.BR>

⁵<https://github.com/roneysco/Fake.br-Corpus>

⁶<https://github.com/KaiDMML/FakeNewsNet/tree/old-version>

⁷<https://github.com/KaiDMML/FakeNewsNet>

⁸<https://github.com/prc992/FakeTweet.Br>

⁹<https://www.cs.ucsb.edu/william/data/liardataset.zip>

Dataset	C1	C2	C3	C4	C5	C6	C7	C8
Bracis2019FakeNews [22]	x		x		x		x	x
BS Detector [29]	x	x			x			
BuzzFace [28]	x	x			x			
BuzzFeedNews [14]	x	x			x			
BuzzFeedNews [29]	x	x			x			
Celebrity [24]	x							
CredBank [29]	x				x			
DataSet Emergent [40]	x				x			
DistrustRank [37]	x				x			
Facebook para Detective [33]		x						
Factck.Br Corpus [20]	x		x		x	x	x	x
FakeBr Corpus [18]	x		x		x			x
FakeNews vs Satire [10]	x				x			
FakeNewsAMT [24]	x				x			
FakeNewsData1 [13]	x							
FakeNewsNet1 [29]	x	x			x		x	x
FakeNewsNet2 [30]	x	x			x		x	x
FakeTweet.Br Corpus [4]	x		x		x			x
KV [5]	x				x			
Large-scale Training Dataset [12]	x							
LIAR [36]	x						x	x
PoliticalNews [3]	x							
PolitiFact para XFake [39]	x						x	
RST-SVM Dataset [26]	x				x			
Signal Media para Evaluating M. L. Algorithms [9]	x				x			
Soc-LiveJournal [32]		x						
Twitter e Sina Weibo para CSI [27]	x	x			x			
Twitter e Sina Weibo para EANN [27]	x	x			x			
Twitter e Sina Weibo para Early Detection [16]	x	x			x			
Twitter e Sina Weibo para TCNN-URG [25]	x	x			x			
Twitter Auto Identifying Fake News [2]	x				x		x	
Twitter para Content Polluters [21]	x	x			x			
Twitter para Mitigation via Point Process [6]	x	x			x			
Twitter para TraceMiner [38]	x	x			x		x	
Twitter Trec [32]	x	x			x			

LEGENDA:
C1-Dados de Publicação ----- C2-Dados de Propagação----- C3-Idioma Português
C4-Modelo de Dados Conceitual -- C5-Politemático ----- C6-Atualizável
C7-Agência de Checagem ----- C8-Processo de Construção Definido

Tabela 1: Aplicação do Modelo Comparativo

disso, nenhuma dessas iniciativas disponibiliza *datasets* que contêm dados de propagação da notícia.

Destaca-se, também, em todos os trabalhos analisados, a ausência de modelos conceituais que favorecessem o entendimento dos aspectos essenciais por meio de níveis mais altos de abstração.

Diante do exposto, identificou-se que, dentre os trabalhos referentes à construção de *datasets* destinados a aplicação de métodos de detecção de *Fake News*, poucos deles disponibilizam dados de propagação e esses poucos não possuem notícias no idioma português, o que inviabiliza a aplicação de métodos que demandem dados de propagação de notícias nesse idioma.

3 PROCESSO DE CONSTRUÇÃO

Esta seção apresenta a metodologia adotada no desenvolvimento do *FakeNewsSetGen*, processo de construção de *datasets* proposto por este trabalho. Além disso, descreve ainda os dois principais modelos resultantes desse desenvolvimento: o modelo de dados conceitual e o modelo macro-funcional.

3.1 Metodologia de Desenvolvimento

O levantamento de requisitos¹⁰ foi a base para a especificação do *FakeNewsSetGen*. A partir desse levantamento foi possível identificar atributos por meio da observação (i.e.: engenharia reversa) dos

¹⁰Fase da engenharia de requisitos que busca levantar informações sobre o que o sistema deve fazer [23].

datasets utilizados pelos métodos do estado da arte de detecção de *Fake News*, referenciados na Tabela 1.

Além da identificação desses atributos que, por sua vez, já viabiliza a representação da demanda de dados pelos métodos existentes, informações disponíveis em diferentes MDDN foram analisadas e, dessa forma, outros atributos foram identificados.

O conjunto de atributos resultante da engenharia reversa aplicada e da análise das informações disponibilizadas por MDDN foi, então, estruturado e abstraído em um modelo de dados conceitual. Esse modelo foi concebido de forma que *datasets* gerados, segundo sua estrutura, possam ser utilizados por diferentes métodos de detecção de *Fake News*, bem como possam ser compatíveis com diferentes MDDN.

Ademais, por intermédio da observação dos trabalhos relacionados que descrevem processos de construção de *datasets* sobre *Fake News*, o levantamento de requisitos ainda possibilitou a identificação das principais funcionalidades a serem incorporadas ao *FakeNewsSetGen*.

Com base no modelo de dados conceitual desenvolvido e nas funcionalidades identificadas, um modelo macro-funcional foi criado para descrever conceitualmente o funcionamento do *FakeNewsSetGen*. Esse modelo funcional favorece o entendimento de como e quando ocorrem a coleta, o processamento e o armazenamento dos dados referentes a cada conjunto de atributos do modelo de dados conceitual.

O presente trabalho desenvolveu ainda uma implementação base compatível com o processo proposto. Disponibilizada no repositório *github* do projeto¹¹, essa implementação foi desenvolvida na linguagem *Python* e possui funcionalidades que possibilitam o resgate dos dados de divulgação de notícias no *Twitter*. A implementação desenvolvida pode ser adaptada para atender a diferentes cenários tanto por meio de customizações (i.e.: ajustes no código da solução implementada) quanto por intermédio de parametrizações (i.e.: ajustes de parâmetros de entrada).

Algumas customizações na implementação base podem, por exemplo, permitir a interação com diferentes redes sociais. Já a escolha de outras entidades externas, tais como mídias virtuais e agências de checagem de fatos com as quais o processo vai interagir em cada aplicação, pode ser realizada simplesmente por meio de parametrizações. As instruções para a configuração desses parâmetros de entrada podem ser obtidas no repositório do projeto.

3.2 Modelo de Dados Conceitual

Ilustrado na Figura 1, o modelo de dados conceitual explicita os grupos de informação e as relações entre eles que são relevantes para um ou mais métodos de detecção de *Fake News* do estado da arte. Para apresentação desse modelo foi utilizada a notação de Diagramas de Classes de Análise da UML [1]. Abaixo segue uma breve descrição das classes do modelo desenvolvido.

- **Meio de Divulgação** - Compreende todos os canais por onde as notícias podem ser divulgadas (i.e., os MDDN) e representa uma generalização das classes Mídia Virtual e Rede Social;
- **Rede Social** - Representa estruturas formadas por pessoas e/ou organizações que se conectam a partir de interesses ou valores comuns (e.g.: *Facebook* e *Twitter*);

¹¹<https://github.com/kamplus/FakeNewsSetGen>




Figura 1: Modelo de Dados Conceitual.


- **Mídia Virtual** - Caso particular da classe Meio de Divulgação que se refere às mídias digitais como os jornais online, por exemplo;
- **Fonte Fidedigna** - Corresponde a uma agência de checagem de fatos (e.g.: Lupa, Aos Fatos e AFP) ou a uma mídia virtual renomada (e.g.: portais de notícias G1 e R7) que fornecem credibilidade ao processo de rotulação de notícias;
- **Resultado da Checagem** - Armazena o rótulo (fake e não fake) de cada notícia obtido a partir de fontes fidedignas;
- **Notícia** - Engloba características específicas da notícia checada por uma fonte fidedigna e pode conter diferentes componentes (e.g.: texto, imagem e áudio). Somente são consideradas notícias com pelo menos uma divulgação na RSV.
- **Divulgação** - Representa todas as divulgações sofridas por uma determinada notícia ou desencadeadas a partir de outra divulgação (e.g. *tweets* e *retweets*);
- **Componente** - Engloba atributos de diferentes tipos (e.g.: texto, imagem e áudio) que podem estar presentes em notícias e divulgações;
- **Conta** - Contém dados das contas de usuários de meios de divulgação (e.g. idade da conta, contas seguidoras, contas seguidas);
- **Proprietário** - Compreende os dados do responsável por cada conta de usuário, sempre que esse responsável for identificado.

3.3 Modelo Macro-Funcional

A Figura 2 ilustra graficamente o modelo macro-funcional do *FakeNewsSetGen*. Nela, os retângulos de cantos arredondados representam as etapas do processo; os retângulos com cantos afiados representam entidades externas ao processo; a seta contínua indica uma relação de generalização entre as entidades externas; e as setas tracejadas indicam fluxos de dados.

Sempre que executado, o *FakeNewsSetGen* permite gerar uma instância de *dataset* denominada *FakeNewsSet*, compatível com o modelo de dados conceitual apresentado na seção anterior. Para tanto, o processo executa as quatro etapas descritas a seguir.

Resumida pelo Algoritmo 1, a primeira etapa do processo (identificação de notícias rotuladas) recebe como parâmetro de entrada o conjunto S das fontes fidedignas a serem consultadas em busca de notícias previamente rotuladas. Cada fonte $s \in S$ possui um

Figura 2: Modelo Macro-Funcional do *FakeNewsSetGen*

atributo $s.l$ que contém o endereço do *feed* de notícias de s . Assim, para cada $s \in S$, esta etapa recupera, a partir do *feed* $s.l$, o conjunto $URLs$ de endereços de notícias previamente rotuladas por s . Em seguida, para cada $url \in URLs$, a notícia rotulada localizada em url é recuperada e armazenada em um conjunto de notícias rotuladas N^R , inicialmente vazio. Cada $n^r \in N^R$ possui, dentre outros, os atributos $n^r.id$ e $n^r.text$ que contém, respectivamente, o identificador e o texto da notícia n^r .

Algoritmo 1: Identificar notícias rotuladas

Entrada: Fontes fidedignas selecionadas, S
Saída: Conjunto notícias rotuladas, N^R

```

1 para cada  $s \in S$  faça
2    $URLs \leftarrow \text{ColetarURLsFeedRSS}(s.l)$ ;
3   para cada  $url \in URLs$  faça
4      $N^R \leftarrow N^R \cup \text{lerNoticiaRotulada}(url)$ 
5   fim
6 fim
7 retorna  $N^R$ ;
```

Posteriormente, ocorre a segunda etapa do processo que se refere à identificação dos eventos de divulgação na rede social e nas mídias virtuais de cada notícia rotulada de N^R , conforme retratado no Algoritmo 2. Esta etapa realiza iterações sobre o conjunto N^R , de modo que, para cada $n^r \in N^R$, $n^r.text$ é pré-processado¹² a fim de se obter um conjunto de palavras chave *query* que é utilizado, juntamente com o intervalo de tempo de restrição da busca t , para identificar divulgações de n^r na rede social e nas mídias virtuais. Cabe ressaltar que os textos das divulgações passam pelas mesmas operações de pré-processamento que $n^r.text$, de tal forma a simplificar a comparação entre as *strings* textuais. O conjunto $URLsDIV$ recebe as urls dessas divulgações. Em seguida, para cada $urlDiv \in URLsDIV$, um par ordenado $(n^r.id, urlDiv)$ é criado e armazenado no conjunto ND . Dessa forma, ao final da etapa 2, cada $nd \in ND$ possui os atributos $nd.idNoticia$ e $nd.urlDiv$ que contém, respectivamente, o identificador da notícia n^r e o endereço da divulgação de n^r ocorrida na rede social ou na mídia virtual. Por fim, os conjuntos N^R e ND são armazenados no *FakeNewsSet*.

¹²O pré-processamento envolve as seguintes operações sobre *strings* textuais: remoção de *stop words* e tokenização [11].

Algoritmo 2: Associar notícias com divulgações

Entrada: (1) Notícias rotuladas, N^R
 (2) Intervalo de tempo a ser utilizado para restringir a busca por divulgações, t
Saída: Conjunto de associações entre os identificadores de notícias e de divulgações, ND

```

1 para cada  $n^r \in N^R$  faça
2   query, URLsDIV  $\leftarrow \emptyset$ ;
3   query  $\leftarrow$  PreProcessar( $n^r.text$ );
4   URLsDIV  $\leftarrow$  PesquisarDivulgacoes(query,  $t$ );
5   se  $URLSDIV \neq \emptyset$  então
6     para cada  $urlDiv \in URLsDIV$  faça
7        $ND \leftarrow ND \cup \{(n^r.id, urlDiv)\}$ 
8     fim
9   fim
10 fim
11 Armazenar( $N^R$ );
12 Armazenar( $ND$ );
13 retorna  $ND$ ;
```

Em seguida, ocorre a terceira etapa do processo (resumida no Algoritmo 3) que se refere à coleta (i.e. recuperação) dos detalhes das divulgações de notícia provenientes das mídias virtuais e/ou das redes sociais. Essa etapa realiza iterações sobre o conjunto ND , de modo que para cada $nd \in ND$, um método recupera os dados da divulgação a partir de $nd.urlDiv$ sobre a notícia $nd.idNoticia$. Esses dados são então armazenados em um conjunto de divulgações D , onde cada $d \in D$ possui, entre outros, o atributo $d.mddn$ que indica se a divulgação provém de uma rede social rsv ou de uma mídia virtual mv . Por fim, o conjunto de divulgações D é armazenado no *FakeNewsSet*.

Algoritmo 3: Coletar divulgações

Entrada: Conjunto de associações entre os identificadores de notícias e de divulgações, ND
Saída: Conjunto de divulgações de notícia, D

```

1 para cada  $nd \in ND$  faça
2    $D \leftarrow D \cup \text{Obter}(\text{nd.urlDiv})$ ;
3 fim
4 Armazenar( $D$ );
5 retorna  $D$ ;
```

Denominada *Coletar Usuários*, a quarta e última etapa do processo é responsável por recuperar os dados dos usuários envolvidos em divulgações de notícias na rede social. Apresentada no Algoritmo 4, esta etapa realiza iterações sobre o conjunto D , de modo que para cada divulgação $d \in D$ onde $d.mddn = rsv$, um método coleta os dados do usuário u divulgador de d , assim como os usuários seguidores e seguidos associados a u na rede social correspondente. Esses dados coletados são então armazenados inicialmente em um conjunto de usuários U e, posteriormente, no *FakeNewsSet*.

É importante enfatizar que uma vez gerado, o *FakeNewsSet* pode ser atualizado por meio de reiteradas execuções do *FakeNewsSetGen*,

Algoritmo 4: Coletar usuários

Entrada: Conjunto de divulgações da notícia, D
Saída: Conjunto de usuários divulgadores, incluindo os seus respectivos seguidores e seguidos, U

```

1 para cada  $d \in D$  faça
2   se  $d.mddn = rsv$  então
3      $U \leftarrow U \cup \text{Obter}(d)$ ;
4   fim
5 fim
6 Armazenar( $U$ );
7 retorna  $U$ ;
```

dando origem a novas instâncias do *dataset*. Assim, novas notícias rotuladas provenientes de fontes fidedignas, bem como seus respectivos dados de propagação podem ser adicionados ao *FakeNewsSet* de forma incremental.

4 ESTUDO DE CASO

4.1 Protótipo

A fim de demonstrar a viabilidade de aplicação do processo proposto, um protótipo foi customizado a partir de uma implementação base do *FakeNewsSetGen* de forma a coletar notícias em língua portuguesa disponíveis em três agências de checagem de fatos brasileiras (*Lupa*, *Aos Fatos* e *AFP*) e em duas mídias virtuais nacionais de renome (*G1* e *R7*), além de obter divulgações dessas notícias ocorridas na rede social do *Twitter*.

Uma das principais customizações implementadas foi decorrente da falta de padronização dos rótulos utilizados pelas agências de checagens para classificar notícias como *fake* e não *fake*. A agência *Lupa*, por exemplo, utiliza os rótulos 'VERDADEIRO', 'VERDADEIRO MAS', 'AINDA É CEDO PARA DIZER', 'EXAGERADO', 'CONTRADITÓRIO', 'SUBESTIMADO', 'INSUSTENTÁVEL' e 'FALSO'. Neste caso, o protótipo foi implementado de forma a selecionar apenas notícias com os rótulos 'FALSO' e 'VERDADEIRO', desprezando as demais. Com relação à rede social, o protótipo foi ajustado para utilizar a interface do *Twitter* e se adequar às características e restrições tecnológicas (e.g., uso de credenciais de acesso e limite no número de consultas permitido por sessão de acesso) impostas pelo uso da API dessa rede social.

O protótipo desenvolvido foi executado de forma modularizada, de acordo com as etapas do processo descritas na Seção 3.3. Cerca de setenta notícias provenientes de atualizações diárias das fontes indicadas foram acrescentadas ao *dataset* durante 60 dias. Após a coleta, essas notícias foram associadas aos seus respectivos *tweets*, *retweets*, usuários divulgadores, seguidores e seguidos foram coletadas. Os dados obtidos por cada módulo executado foram persistidos e assim foi construída uma instância *FakeNewsSet*, composta de notícias publicadas entre março de 2017 e maio de 2020.

4.2 Dataset Gerado

A Tabela 2 apresenta um resumo estatístico da instância *FakeNewsSet* gerada. Dentre as estatísticas apresentadas, destaca-se o elevado desbalanceamento entre os totais de divulgações (*tweets* e *retweets*)

de notícias *fake* e *not Fake*. Esse desbalanceamento também foi observado no estudo de Shu et al. [31], corroborando, dessa forma, a tendência que as *fake news* venham a atingir um maior volume de propagação do que as notícias *not Fake*[27].

Recursos	Fake	notFake
Notícias	300	300
Divulgações (tweets)	20.498	6.506
Divulgações (retweets)	17.927	4.816
Usuários divulgadores	15.983	
Média de seguidores por usuário	96.239	
Média de seguidos por usuário	6.120	
Média de notícias por usuário	1,53	
Média de usuários por notícia	40,7	

Tabela 2: Estatísticas da instância *FakeNewsSet* gerada

É importante destacar que o *dataset* gerado contém informações compatíveis com a estrutura prevista no modelo de dados conceitual exposto na Seção 3.2. O Quadro 1 apresenta um exemplo simplificado de registro de notícia rotulada como ‘*fake*’, incluída no *FakeNewsSet*.

Notícia: ‘Homem que morreu atropelado em São Paulo tem atestado de óbito como morte por Covid-19.’
Data: 02-04-2020
Fonte: Aos Fatos
Resultado da Checagem: ‘O acidente citado na peça de desinformação ocorreu, na verdade, em 1 de março no trecho da estrada em Mogi Guaçu, município que ainda não registrou casos do novo coronavírus.’
Quantidade de divulgações no Twitter: 30
Exemplo de divulgação no Twitter: ‘Seria muito engraçado se não fosse trágico e criminoso!!! Homem que morreu atropelado tem atestado de morte por Covid-19.’
Quantidade de propagações dessa divulgação: 4
Características da conta divulgadora: Segue 15114 usuários e é seguido por outros 11524.
Data de criação da conta: 10-12-2009.

Quadro 1: Exemplo de *Fake News* do *FakeNewsSet*

4.3 Avaliação

Esta subseção tem como objetivo mostrar que a instância do *FakeNewsSet* gerada pelo protótipo do *FakeNewsSetGen* permite realizar experimentos tanto com métodos baseados no conteúdo da notícia quanto com métodos que se baseiam em dados de propagação, viabilizando uma comparação direta entre os desempenhos desses métodos na detecção de *Fake News*. A Tabela 3 apresenta o conjunto de métodos utilizados neste estudo de caso, evidenciando as principais informações utilizadas por cada um deles, assim como as principais classes do modelo de dados conceitual que contém essas informações. Detalhes sobre o funcionamento de cada método podem ser consultados nas respectivas referências. Cabe enfatizar que, de fato, no conjunto de métodos utilizados estão exemplares que somente demandam informações sobre o conteúdo das notícias e exemplares que requerem informações sobre as propagações dessas notícias, viabilizando, portanto, a comparação entre métodos com diferentes necessidades de informação.

Método	Principais informações utilizadas	Principais classes
ICS [7]	Conta usuário publicador/propagador	Notícia Conta
Detective [33]	Conta usuário publicador/propagador	Notícia Conta
Naive Bayes [19]	Texto da notícia publicada	Notícia Componente
Ada Boost [19]	Texto da notícia publicada	Notícia Componente
SVM [19]	Texto da notícia publicada	Notícia Componente

Tabela 3: Demanda dos métodos de detecção de *Fake News*

Para experimentação e validação do *FakeNewsSetGen*, os métodos selecionados foram aplicados ao *FakeNewsSet* através de validação cruzada [15] com 10 conjuntos, sendo a acurácia e a F1 as métricas de avaliação de desempenho adotadas. Mesmo sem ter sido utilizada nos estudos originais dos métodos em questão, a métrica F1 foi calculada a fim de analisar um possível impacto do desbalanceamento entre as quantidades de divulgações de notícias *fake* e *not fake* nos resultados da aplicação dos métodos no *FakeNewsSet*. Em seguida, os resultados obtidos foram comparados com os originalmente publicados pelos trabalhos que propuseram tais métodos. A Tabela 4 permite comparar tais resultados. De uma forma geral, pode-se perceber que todos os métodos obtiveram bons resultados, tanto nos *datasets* originais, quanto no *FakeNewsSet*. Além disso, percebe-se que os resultados obtidos pelos métodos a partir do *FakeNewsSet* foram comparáveis com os obtidos pelos trabalhos correspondentes nos seus respectivos *datasets*, com exceção do Naive Bayes e do SVM. Essa exceção pode ser justificada pela diferença do tamanho médio das notícias dos *datasets*, o que impacta consideravelmente nos métodos baseados em análise de texto. Tais fatos são indicadores positivos quanto à correteza dos dados coletados e, consequentemente, quanto à adequação do processo de construção de *datasets* proposto.

	Dataset original		FakeNewsSet	
Método	Acurácia	F1	Acurácia	F1
ICS [7]	0,9402	-	0,9591	0,9594
Detective [33]	0,9791	-	0,9793	0,9793
Naive Bayes [19]	0,8400	-	0,7817	0,7783
Ada Boost [19]	0,9300	-	0,9017	0,9016
SVM [19]	0,9400	-	0,8433	0,8429

Tabela 4: Comparação dos resultados obtidos

5 CONSIDERAÇÕES FINAIS

A detecção de *Fake News* nos meios digitais de divulgação de notícias não é trivial. Vários métodos baseados em aprendizado de máquina têm sido propostos. Embora alguns desses métodos utilizem dados de propagação de notícias em redes sociais, poucos *datasets* existentes contemplam esses dados e, entre esses poucos, nenhum contém notícias em português - o que prejudica a avaliação desses métodos nesse idioma.

Assim, este trabalho propõe o processo *FakeNewsSetGen*, capaz de construir *datasets* compostos de dados sobre o conteúdo de notícias em português e de dados referentes a suas propagações. Para ilustrar a viabilidade e adequação do *FakeNewsSetGen*, foi realizado um estudo de caso que abrange a implementação de um protótipo.

Por meio da aplicação desse protótipo, foi criado o *dataset FakeNewsSet* contendo notícias em português (incluindo os dados de propagação). Em seguida, foram aplicados ao *FakeNewsSet* cinco métodos de detecção de *Fake News* com diferentes tipos de demandas de dados (dois deles exigindo dados de propagação). Os resultados desses experimentos foram comparados, demonstrando o potencial de utilização do processo proposto e do *dataset* por ele construído.

Baseadas nas limitações da solução proposta, as perspectivas de trabalho futuro incluem: implementar interfaces com outras RSV e com outras fontes fidedignas; estender o processo para gerar *Fake News* a partir de notícias verdadeiras, com base em técnicas de fabricação identificadas por trabalhos do estado da arte; e aperfeiçoar o processo de recuperação de divulgações de notícias nas RSV.

AGRADECIMENTO

O presente trabalho foi realizado com apoio do Ministério da Ciência, Tecnologia, Inovações e Comunicações, do Ministério da Saúde e do Conselho Nacional de Desenvolvimento Científico e Tecnológico - Código de Financiamento (CNPq) 401662/2020-9.

REFERÊNCIAS

- [1] Eduardo Bezerra. 2007. *Princípios de Análise e Projeto de Sistemas com UML*. Vol. 2. Elsevier, Rio de Janeiro, RJ, Brazil.
- [2] C. Buntain and J. Golbeck. 2017. Automatically Identifying Fake News in Popular Twitter Threads. In *2017 IEEE International Con on Smart Cloud (SmartCloud)*. IEEE, New York, NY, USA, 208–215. <https://doi.org/10.1109/SmartCloud.2017.40>
- [3] Sonia Castelo et al. 2019. A Topic-Agnostic Approach for Identifying Fake News Pages. In *Companion Proceedings of The 2019 World Wide Web Conference (San Francisco, USA) (WWW '19)*. ACM, New York, NY, USA, 975–980.
- [4] Paulo Roberto Cordeiro and Vladia Pinheiro. 2019. Um Corpus de Notícias Falsas do Twitter e Verificação Automática de Rumores em Língua Portuguesa. In *STIL - Brazilian Symposium in Information and Human Language Technology*. IEEE, Salvador, BA, Brazil, 220–228.
- [5] X. Dong et al. 2014. Knowledge Vault: A Web-Scale Approach to Probabilistic Knowledge Fusion. In *ACM SIGKDD international Con on Knowledge discovery and data mining*. ACM, New York, NY, USA, 601–610.
- [6] Mehrdad Farajtabar et al. 2017. Fake News Mitigation via Point Process Based Intervention. In *Proceedings of the 34th International Con on Machine Learning (Sydney, Australia) (ICML'17)*. JMLR.org, Sydney, NSW, Australia, 1097–1106.
- [7] Paulo Márcio Souza Freire and Ronaldo Ribeiro Goldschmidt. 2019. Fake News Detection on Social Media via Implicit Crowd Signals. In *Proceedings of the 25th Brazilian Symposium on Multimedia and the Web (Rio de Janeiro, Brazil) (WebMedia '19)*. ACM, New York, NY, USA, 521–524.
- [8] Paulo Márcio Souza Freire and Ronaldo Ribeiro Goldschmidt. 2019. Uma Introdução ao Combate Automático às Fake News em Redes Sociais Virtuais. In *Tópicos de Gerenciamento de Dados e Informação (Rio de Janeiro, Brazil) (34th SBBD)*. SBC, Fortaleza, CE, Brazil, 38–67. <http://http://sbbd.org.br/2019/proceedings/>
- [9] S. Gilda. 2017. Evaluating machine learning algorithms for fake news detection. In *2017 IEEE 15th Student Con on Research and Development (SCOREd)*. IEEE, Putrajaya, Malaysia, 110–115. <https://doi.org/10.1109/SCOREd.2017.8305411>
- [10] Jennifer Golbeck et al. 2018. Fake news vs satire: A dataset and analysis. In *WebSci 2018 - Proceedings of the 10th ACM Conference on Web Science*. ACM, New York, NY, USA, 17–21. <https://doi.org/10.1145/3201064.3201100>
- [11] Vishal Gupta et al. 2009. A survey of text mining techniques and applications. *Journal of emerging technologies in web intelligence* 1 (2009), 60–76.
- [12] S. Helmstetter et al. 2018. Weakly Supervised Learning for Fake News Detection on Twitter. In *ACM International Conference*. IEEE, Barcelona, Spain, 274–277.
- [13] Benjamin D. Horne and Sibel Adali. 2017. This Just In: Fake News Packs a Lot in Title, Uses Simpler, Repetitive Content in Text Body, More Similar to Satire than Real News. In *Association for the Advancement of Artificial Intelligence. The 2nd International Workshop on News*, New York, USA, 163–173.
- [14] Christian Janze and Marten Risius. 2017. Automatic Detection of Fake News on Social Media Platforms. In *PACIS 2017*. AISel, Frankfurt, Germany, 261.
- [15] Ron Kohavi et al. 1995. A study of cross-validation and bootstrap for accuracy estimation. In *Ijcai*, Vol. 14. researchgate, Montreal, Canada, 1137–1145.
- [16] Y. Liu et al. 2018. Early Detection of Fake News on Social Media Through Propagation Path Classification with Recurrent and Convolutional Networks. In *AAAI Con on Artificial Intelligence*. AAAI, New Jersey, USA, 354–361.
- [17] Yelena Mejova and Kyriaki Kalimeri. 2020. Advertisers Jump on Coronavirus Bandwagon: Politics, News, and Business. *ArXiv abs/2003.00923* (2020), 90–101.
- [18] Rafael A. Monteiro et al. 2018. Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results. In *Computational Processing of the Portuguese Language*. Springer International, Cham, 324–334.
- [19] Marcos Paulo Moraes, Jonice de Oliveira Sampaio, and Anderson Cordeiro Charles. 2019. Data Mining Applied in Fake News Classification through Textual Patterns. In *Proceedings of the 25th Brazilian Symposium on Multimedia and the Web (RJ, Brazil) (WebMedia '19)*. ACM, New York, USA, 321–324.
- [20] João Moreno and Graça Bressan. 2019. FACTCK.BR: A New Dataset to Study Fake News. In *Proceedings of the 25th Brazilian Symposium on Multimedia and the Web (Rio de Janeiro, Brazil) (WebMedia '19)*. ACM, New York, NY, USA, 525–527.
- [21] Mehdi Nasim et al. 2018. Real-time Detection of Content Polluters in Partially Observable Twitter Networks. In *Companion Proceedings of the The Web Con 2018 (Lyon, France) (WWW '18)*. International World Wide Web Con Steering Committee, Republic and Canton of Geneva, Switzerland, 1331–1339.
- [22] Thiago Covões Pedro Faustini. 2019. Fake News Detection Using One-Class Classification. In *2019 8th Brazilian Conference on Intelligent Systems (BRACIS)*. IEEE, Salvador, Brazil, 592–597. <https://doi.org/10.18653/v1/n19-1141>
- [23] Roger Pressman and Bruce Maxim. 2016. *Engenharia de Software-8ª Edição*. McGraw Hill Brasil, Connecticut, EUA.
- [24] V. Pérez-Rosas, B. Kleinberg, A. Lefevre, and R. Mihalcea. 2018. Automatic Detection of Fake News. In *International Conference on Computational Linguistics*. arXiv.org, Santa Fe, New Mexico, USA, 3391–3401.
- [25] Feng Qian et al. 2018. Neural user response generator: Fake news detection with collective user intelligence. *IJCAI International Joint Conference on Artificial Intelligence 2018-July* (2018), 3834–3840.
- [26] Victoria L. Rubin and Niall J. Conroy. 2015. Towards news verification: Deception detection methods for news discourse. In *Hawaii International Conference on System Sciences*. WebSci 2018 - Proceedings of the 10th ACM Conference on Web Science, Ontario, CANADA, 13 pages.
- [27] Natali Ruchansky, Sungyong Seo, and Yan Liu. 2017. CSI: A Hybrid Deep Model for Fake News Detection. In *Proceedings of the 2017 ACM on Con on Information and Knowledge Management (Singapore, Singapore) (CIKM '17)*. ACM, New York, NY, USA, 797–806. <https://doi.org/10.1145/3132847.3132877>
- [28] Giovanni C. Santia and Jake Ryland Williams. 2018. Buzz face: A news veracity dataset with facebook user commentary and egos. In *12th International AAAI Conference on Web and Social Media*. AAAI, Pennsylvania, USA, 531–540.
- [29] Kai Shu et al. 2017. Fake News Detection on Social Media: A Data Mining Perspective. *SIGKDD Explor. Newsl.* 19, 1 (Sept. 2017), 22–36.
- [30] Kai Shu et al. 2020. FakeNewsNet: A Data Repository with News Content, Social Context, and Spatiotemporal Information for Studying Fake News on Social Media. *Big Data* 8, 3 (2020), 171–188. <https://doi.org/10.1089/big.2020.0062> arXiv:https://doi.org/10.1089/big.2020.0062 PMID: 32491943.
- [31] Kai Shu, Deepak Mahudeswaran, and Huan Liu. 2019. FakeNewsTracker: a tool for fake news collection, detection, and visualization. *Computational and Mathematical Organization Theory* 25, 1 (01 Mar 2019), 60–71.
- [32] Ajitesh Srivastava et al. 2018. FActCheck: Keeping Activation of Fake News at Check. In *Proceedings of the 17th International Conf on Autonomous Agents and MultiAgent Systems (Stockholm, Sweden) (AAMAS '18)*. International Foundation for Autonomous Agents and Multiagent Systems, Richland, SC, 2079–2081.
- [33] Sebastian Tschitschek et al. 2018. Fake News Detection in Social Networks via Crowd Signals. In *Companion Proceedings of the The Web Con 2018 (Lyon, France) (WWW '18)*. International World Wide Web Con Steering Committee, Republic and Canton of Geneva, Switzerland, 517–524.
- [34] Soroush Vosoughi et al. 2017. Rumor Gauge: Predicting the Veracity of Rumors on Twitter. *ACM Trans. Knowl. Discov. Data* 11, 4, Article 50 (July 2017), 36 pages.
- [35] Patrick Wang et al. 2018. Is This the Era of Misinformation Yet: Combining Social Bots and Fake News to Deceive the Masses. In *Companion Proceedings of the The Web Con 2018 (Lyon, France) (WWW '18)*. International WWW Con Steering Committee, Republic and Canton of Geneva, Switzerland, 1557–1561.
- [36] William Yang Wang. 2017. "Liar, Liar Pants on Fire": A New Benchmark Dataset for Fake News Detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Vancouver, Canada, 422–426. <https://doi.org/10.18653/v1/P17-2067>
- [37] Vinicius Woloszyn and Wolfgang Nejdl. 2018. DistrustRank: Spotting False News Domains. In *Proceedings of the 10th ACM Con on Web Science (Amsterdam, Netherlands) (WebSci '18)*. ACM, New York, NY, USA, 221–228.
- [38] Liang Wu and Huan Liu. 2018. Tracing Fake-News Footprints: Characterizing Social Media Messages by How They Propagate. In *Proceedings of the Eleventh ACM International Con on Web Search and Data Mining (Marina Del Rey, CA, USA) (WSDM '18)*. ACM, New York, NY, USA, 637–645.
- [39] Fan Yang et al. 2019. XFake: Explainable Fake News Detector with Visualizations. In *The World Wide Web Conference (San Francisco, CA, USA) (WWW '19)*. ACM, New York, NY, USA, 3600–3604. <https://doi.org/10.1145/3308558.3314119>
- [40] Qiang Zhang et al. 2018. Ranking-based Method for News Stance Detection. In *Proceedings The WebCon 2018 (Lyon, France) (WWW '18)*. World Wide Web Con Steering Committee, Rep. Canton Geneva, Switzerland, 41–42.
- [41] Xinyi Zhou and Reza Zafarani. 2018. Fake News: A Survey of Research, Detection Methods, and Opportunities. , arXiv:1812.00315 pages. arXiv:1812.00315 [cs.CL]